

Relatório de Análise de Dados – E-commerce Brasileiro

Autores: Gabriel dos Santos Souza e Leandro de Moraes **Turma:** 3º Período - ADS
Embarque Digital **Data:** 08 de Novembro de 2025

1. Sumário Executivo

Divisão de Responsabilidades

Para a execução deste projeto, as responsabilidades foram divididas da seguinte forma:

Membro da Equipe	Responsabilidades Principais	Notebooks/Fases
Gabriel dos Santos Souza	Limpeza de Dados, Feature Engineering, Análise Exploratória (EDA)	01_data_cleaning.py , 02_feature_engineering.py , 03_exploratory_analysis.py , 04_eda_temporal_categorical.py
Leandro de Moraes	Inferência Estatística, Cálculo de KPIs, Geração de Insights, Relatório Analítico	05_statistical_inference.py , 06_kpis_insights.py , Relatório Analítico, README

| **Leandro de Moraes** | Inferência Estatística, Cálculo de KPIs, Geração de Insights, Relatório Analítico |

Este relatório apresenta uma análise aprofundada dos dados de vendas de um e-commerce brasileiro, cobrindo o período de janeiro a outubro de 2024. A análise resultou em insights acionáveis para a direção, com foco em otimização de receita, performance logística e comportamento do cliente. Os principais achados são:

- 1. Otimização de Pagamentos é Crucial para a Receita:** A taxa de cancelamento de pedidos realizados com **Boleto (18.6%)** e **Cartão de Débito (18.7%)** é significativamente mais alta que a de **Cartão de Crédito (8.4%)** e **PIX (8.8%)**. Uma campanha para incentivar o uso de PIX e crédito, ou um sistema de lembretes para pagamento de boletos, poderia recuperar uma parcela significativa da receita perdida.
- 2. Eletrônicos Dominam a Receita, mas com Margens Apertadas:** A categoria de **Eletrônicos** representa **53% da receita total**, impulsionada por um ticket médio altíssimo (R\$ 2.762). No entanto, a categoria também possui a maior média de desconto (5.1%), sugerindo uma sensibilidade ao preço. Estratégias de cross-selling com produtos de margem maior, como acessórios, podem aumentar a lucratividade.
- 3. Performance Logística Regional Apresenta Desafios:** A região **Nordeste** registra a **maior taxa de atraso (49.4%)** e o segundo maior custo de frete médio (R\$ 36.43), atrás apenas da região Norte. Isso indica gargalos logísticos que podem estar impactando a satisfação do cliente e a recompra. Uma revisão dos parceiros logísticos ou a implementação de um centro de distribuição local são ações recomendadas.
- 4. Sazonalidade de Vendas é Moderada, mas Relevante:** As vendas apresentam um pico em **Março**, tanto em volume de pedidos quanto em receita. Compreender os fatores por trás dessa alta (ex: datas comemorativas, comportamento do consumidor pós-férias) pode permitir a replicação de estratégias bem-sucedidas em outros meses do ano.

2. Dados e Metodologia

2.1. Fonte e Estrutura dos Dados

Para esta análise, foi utilizado um conjunto de dados sintético, gerado para simular as operações de um e-commerce brasileiro com 5.000 pedidos iniciais. O dataset contém informações detalhadas sobre pedidos, clientes, produtos, pagamentos e entregas. As principais colunas incluem:

- **Identificadores:** Order_ID

- **Datas:** `Order_Date` , `D_Forecast` (previsão), `D_Date` (real)
- **Geografia:** `UF` , `Region`
- **Produto:** `Category` , `Subcategory`
- **Valores:** `Subtotal` , `Discount` , `P_Service` (frete), `Total`
- **Status:** `Payment_Method` , `Purchase_Status` , `Services`

2.2. Preparação e Limpeza dos Dados

O dataset bruto passou por um rigoroso processo de limpeza e preparação para garantir a qualidade e a confiabilidade da análise. As seguintes etapas foram executadas:

1. **Tratamento de Tipos:** As colunas de data foram convertidas para o formato `datetime` , e as colunas numéricas foram ajustadas para `float` ou `int` .
2. **Valores Faltantes:** Valores ausentes em `Discount` foram preenchidos com 0 (assumindo ausência de desconto). Em `P_Service` (frete), foram imputados com a mediana do respectivo tipo de serviço. Datas de entrega (`D_Date`) ausentes em pedidos confirmados foram preenchidas com a data prevista para permitir a análise de atraso.
3. **Remoção de Duplicatas:** Foram identificados e removidos 50 registros duplicados baseados no `Order_ID` , mantendo-se a primeira ocorrência.
4. **Tratamento de Outliers:** Outliers em variáveis financeiras (`Total` , `Subtotal` , `P_Service`) foram identificados usando o método Z-score (threshold > 3). Um total de 364 registros com valores extremos foram removidos para não distorcer as análises de tendência central e inferência.

Após a limpeza, o dataset final ficou com **4.636 registros**.

2.3. Feature Engineering

Novas variáveis foram criadas para aprofundar a análise e permitir o cálculo de KPIs complexos:

- `delivery_lead_time` : Tempo total entre a data do pedido e a data da entrega.
- `delivery_delay_days` : Diferença em dias entre a entrega real e a prevista.

- `is_late` : Flag binário ($\frac{1}{0}$) que indica se um pedido atrasou.
 - `is_confirmed` : Flag binário ($\frac{1}{0}$) que indica se o pagamento foi confirmado.
 - `freight_share` : Proporção do valor do frete em relação ao total do pedido.
 - `discount_abs` : Valor absoluto do desconto em Reais.
-

3. Análise Exploratória de Dados (EDA)

3.1. Distribuições e Medidas de Tendência

A análise das principais variáveis numéricas revela uma forte assimetria à direita, comum em dados financeiros. A média do **Ticket Total** é de **R\$ 952,86**, enquanto a mediana é de R\$ 497,78, indicando que um menor número de pedidos de alto valor eleva a média geral.

Métrica	Ticket Total	Prazo de Entrega (dias)	Atraso (dias)	Desconto (%)
Média	R\$ 952,86	10.1	2.9	4.0%
Mediana	R\$ 497,78	9.0	1.0	0.0%
Desvio Padrão	R\$ 1.229,15	6.9	4.9	5.5%
Mínimo	R\$ 21,54	0	-7.0	0.0%
Máximo	R\$ 7.844,19	33	21	20.0%




Figura 1: Histogramas de Ticket Total, Prazo de Entrega e Atraso.

3.2. Análise de Correlações

A matriz de correlação mostra, como esperado, uma correlação quase perfeita entre `Subtotal` e `Total` (0.97). Uma correlação negativa fraca entre `Discount` e `Total` (-0.11) sugere que descontos maiores não necessariamente levam a um aumento do ticket total, podendo estar associados a produtos de menor valor.




Figura 2: Heatmap de correlação entre as principais variáveis numéricas.

3.3. Análise Categórica

Receita por Categoria: A categoria de **Eletrônicos** é a principal fonte de receita, seguida por **Casa e Decoração**. Livros, apesar de terem um alto volume de pedidos, contribuem com a menor parcela da receita devido ao baixo ticket médio.




Figura 3: Análise de Receita, Ticket Médio e Desconto por Categoria.

Performance Logística: O serviço **Standard** é o mais utilizado (70% dos pedidos confirmados), com o frete mais baixo, porém o maior prazo de entrega. O serviço **Same-Day**, embora mais caro, cumpre a promessa de entrega rápida. A taxa de atraso, no entanto, é similar entre os três serviços, pairando em torno de 47%.




Figura 4: Comparativo de Frete, Prazo e Atraso por tipo de serviço.

4. Inferência Estatística

Para validar os achados e fazer generalizações para a população de clientes, foram realizados testes de hipóteses e calculados intervalos de confiança (ICs) com 95% de confiança.

4.1. Verificação de Suposições

Os testes de normalidade (Shapiro-Wilk, D' Agostino-Pearson) rejeitaram a hipótese de normalidade para todas as variáveis financeiras e de tempo ($p < 0.05$). No entanto, devido ao grande tamanho da amostra ($n > 30$), o Teorema do Limite Central nos permite prosseguir com os testes paramétricos, como o Teste t, com robustez.

4.2. Intervalos de Confiança (IC 95%)

Os ICs fornecem uma faixa de valores prováveis para as médias e proporções da população.

- **IC para Ticket Médio Total:** Com 95% de confiança, o ticket médio de todos os clientes do e-commerce está entre **R915,64 e R 990,08**.
- **IC para Taxa de Atraso:** A verdadeira taxa de atraso da operação logística está entre **45.68% e 48.73%**.
- **IC para Taxa de Confirmação:** A proporção de pedidos que são efetivamente pagos e confirmados está entre **88.09% e 89.89%**.




Figura 5: Intervalos de confiança de 95% para as principais métricas de média.

4.3. Testes de Hipóteses

- **Taxa de Confirmação vs. Método de Pagamento:** O teste Qui-Quadrado mostrou uma **associação estatisticamente significativa** ($p < 0.001$) entre o método de pagamento e a confirmação do pedido. Isso confirma que a diferença nas taxas de confirmação entre Boleto/Débito e Crédito/PIX não ocorre ao acaso.
- **Ticket Médio vs. Categoria:** O teste ANOVA revelou **diferenças estatisticamente significativas** ($p < 0.001$) no ticket médio entre as diferentes categorias de produtos, validando que **Eletrônicos** possuem um ticket médio estruturalmente maior que as demais.

5. KPIs e Insights de Negócio

O dashboard abaixo consolida os principais KPIs (Key Performance Indicators) e direciona para os insights mais relevantes.




Figura 6: Dashboard consolidado com os principais KPIs do negócio.

Principais KPIs

Categoria	KPI	Valor
Financeiro	Receita Total (Confirmada)	R\$ 3.915.541,69
	Ticket Médio	R\$ 952,86
	Take-rate de Frete	3.48%
Operacional	Taxa de Confirmação	88.95%
	Taxa de Cancelamento	11.05%
Logístico	Prazo Médio de Entrega	10.1 dias
	Taxa de Atraso	47.20%

Insights Acionáveis

- 1. Ação em Pagamentos:** A diferença de mais de 10 pontos percentuais na taxa de confirmação entre Boletão/Débito e PIX/Crédito é um ponto de atenção. **Recomendação:** Implementar um sistema de recuperação de boletos não pagos (ex: lembretes por e-mail/WhatsApp) e promover o PIX com pequenos incentivos (ex: cashback ou desconto no frete).
- 2. Estratégia de Mix de Produtos:** A alta concentração de receita em Eletrônicos (53%) cria uma dependência. **Recomendação:** Fomentar o crescimento de categorias com boa margem e ticket médio crescente, como **Casa e Decoração** (26% da receita), através de campanhas de marketing direcionadas e kits de produtos (bundles).
- 3. Otimização Logística:** A taxa de atraso de 47% é um ponto crítico que afeta a experiência do cliente. A região Nordeste é a mais impactada. **Recomendação:** Renegociar SLAs (Service Level Agreements) com as transportadoras, diversificar parceiros logísticos na região Nordeste e avaliar a viabilidade de um mini centro de distribuição para reduzir o *lead time*.