

Relatório de Análise de Dados – E-commerce Brasileiro

Autores: Gabriel dos Santos Souza e Leandro de Moraes **Turma:** 3º Período - ADS Embarque Digital **Data:** 08 de Novembro de 2025

1. Sumário Executivo

Divisão de Responsabilidades

Membro da Equipe	Responsabilidades Principais	Notebooks/Fases
Gabriel dos Santos Souza	Limpeza de Dados, Feature Engineering, Análise Exploratória (EDA)	01_data_cleaning.py , 02_feature_engineering.py , 03_exploratory_analysis.py , 04_eda_temporal_categorical.py
Leandro de Moraes	Inferência Estatística, Cálculo de KPIs, Geração de Insights, Relatório Analítico	05_statistical_inference.py , 06_kpis_insights.py , Relatório Analítico, README

Este relatório apresenta uma análise aprofundada dos dados de vendas de um e-commerce brasileiro, cobrindo o período de janeiro a outubro de 2024. A análise resultou em insights acionáveis para a direção, com foco em otimização de receita, performance logística e comportamento do cliente. Os principais achados são:

- Otimização de Pagamentos é Crucial para a Receita:** A taxa de cancelamento de pedidos realizados com **Boleto (18.6%)** e **Cartão de Débito (18.7%)** é significativamente mais alta que a de **Cartão de Crédito (8.4%)** e **PIX (8.8%)**. Uma campanha para incentivar o uso de PIX e crédito, ou um sistema de lembretes para pagamento de boletos, poderia recuperar uma parcela significativa da receita perdida.

2. **Eletrônicos Dominam a Receita, mas com Margens Apertadas:** A categoria de **Eletrônicos** representa **53% da receita total**, impulsionada por um ticket médio altíssimo (R\$ 2.762). No entanto, a categoria também possui a maior média de desconto (5.1%), sugerindo uma sensibilidade ao preço. Estratégias de cross-selling com produtos de margem maior, como acessórios, podem aumentar a lucratividade.
3. **Performance Logística Regional Apresenta Desafios:** A região **Nordeste** registra a **maior taxa de atraso (49.4%)** e o segundo maior custo de frete médio (R\$ 36.43), atrás apenas da região Norte. Isso indica gargalos logísticos que podem estar impactando a satisfação do cliente e a recompra. Uma revisão dos parceiros logísticos ou a implementação de um centro de distribuição local são ações recomendadas.
4. **Sazonalidade de Vendas é Moderada, mas Relevante:** As vendas apresentam um pico em **Março**, tanto em volume de pedidos quanto em receita. Compreender os fatores por trás dessa alta (ex: datas comemorativas, comportamento do consumidor pós-férias) pode permitir a replicação de estratégias bem-sucedidas em outros meses do ano.

2. Dados e Metodologia

2.1. Fonte e Estrutura dos Dados

O modelo de dados utilizado é um esquema estrela (star schema), composto por uma tabela de fatos (FACT_Orders) e quatro tabelas de dimensão (DIM_Customer, DIM_Products, DIM_Delivery, DIM_Shopping). Este modelo facilita a agregação de métricas e a análise por diferentes perspectivas de negócio.




Figura 1: Diagrama de Relacionamento de Entidades (ERD) do Modelo de Dados.

Para esta análise, foi utilizado um conjunto de dados sintético, gerado para simular as operações de um e-commerce brasileiro com 5.000 pedidos iniciais. O dataset contém

informações detalhadas sobre pedidos, clientes, produtos, pagamentos e entregas. As principais colunas incluem:

- **Identificadores:** `Order_ID`
- **Datas:** `Order_Date`, `D_Forecast` (previsão), `D_Date` (real)
- **Geografia:** `UF`, `Region`
- **Produto:** `Category`, `Subcategory`
- **Valores:** `Subtotal`, `Discount`, `P_Service` (frete), `Total`
- **Status:** `Payment_Method`, `Purchase_Status`, `Services`

2.2. Preparação e Limpeza dos Dados

O dataset bruto passou por um rigoroso processo de limpeza e preparação para garantir a qualidade e a confiabilidade da análise. As seguintes etapas foram executadas:

1. **Tratamento de Tipos:** As colunas de data foram convertidas para o formato `datetime`, e as colunas numéricas foram ajustadas para `float` ou `int`.
2. **Valores Faltantes:** Valores ausentes em `Discount` foram preenchidos com 0 (assumindo ausência de desconto). Em `P_Service` (frete), foram imputados com a mediana do respectivo tipo de serviço. Datas de entrega (`D_Date`) ausentes em pedidos confirmados foram preenchidas com a data prevista para permitir a análise de atraso.
3. **Remoção de Duplicatas:** Foram identificados e removidos 50 registros duplicados baseados no `Order_ID`, mantendo-se a primeira ocorrência.
4. **Tratamento de Outliers e Robustez Estatística:** Outliers em variáveis financeiras (`Total`, `Subtotal`, `P_Service`) foram identificados e tratados para evitar a distorção das análises de tendência central e, principalmente, dos testes de inferência subsequentes.

Utilizamos o método **Z-score** com um limiar de **3 desvios-padrão** para identificar valores extremos. Este método é adequado para dados que, embora não sejam estritamente normais, possuem uma distribuição unimodal e simétrica o suficiente para que valores muito distantes da média sejam considerados anômalos.

A remoção de **364 registros** (aproximadamente 7.3% do *dataset* inicial) foi uma decisão metodológica para garantir a **robustez** dos Intervalos de Confiança (ICs) e dos testes de hipóteses (ANOVA), que são sensíveis a valores extremos. Os *outliers* removidos, principalmente nas variáveis `Total` e `Subtotal`, representam transações atípicas que, se mantidas, poderiam inflacionar artificialmente a média e o desvio-padrão, comprometendo a generalização dos resultados para a população de pedidos.

Após a limpeza, o dataset final ficou com **4.636 registros**.

2.3. Feature Engineering

Novas variáveis foram criadas para aprofundar a análise e permitir o cálculo de KPIs complexos:

- `delivery_lead_time`: Tempo total entre a data do pedido e a data da entrega.
 - `delivery_delay_days`: Diferença em dias entre a entrega real e a prevista.
 - `is_late`: Flag binário ($\frac{1}{0}$) que indica se um pedido atrasou.
 - `is_confirmed`: Flag binário ($\frac{1}{0}$) que indica se o pagamento foi confirmado.
 - `freight_share`: Proporção do valor do frete em relação ao total do pedido.
 - `discount_abs`: Valor absoluto do desconto em Reais.
-

3. Análise Exploratória de Dados (EDA)

3.1. Distribuições e Medidas de Tendência

A análise das principais variáveis numéricas revela uma forte assimetria à direita, comum em dados financeiros. A média do **Ticket Total** é de **R\$ 952,86**, enquanto a mediana é de R\$ 497,78, indicando que um menor número de pedidos de alto valor eleva a média geral.

Métrica	Ticket Total	Prazo de Entrega (dias)	Atraso (dias)	Desconto (%)
Média	R\$ 952,86	10.1	2.9	4.0%
Mediana	R\$ 497,78	9.0	1.0	0.0%
Desvio Padrão	R\$ 1.229,15	6.9	4.9	5.5%
Mínimo	R\$ 21,54	0	-7.0	0.0%
Máximo	R\$ 7.844,19	33	21	20.0%




Figura 2: Histogramas de Ticket Total, Prazo de Entrega e Atraso.

3.2. Análise de Correlações

A matriz de correlação mostra, como esperado, uma correlação quase perfeita entre `Subtotal` e `Total` (0.97). Uma correlação negativa fraca entre `Discount` e `Total` (-0.11) sugere que descontos maiores não necessariamente levam a um aumento do ticket total, podendo estar associados a produtos de menor valor.




Figura 3: Heatmap de correlação entre as principais variáveis numéricas.

3.3. Análise Categórica

Receita por Categoria: A categoria de **Eletrônicos** é a principal fonte de receita, seguida por **Casa e Decoração**. Livros, apesar de terem um alto volume de pedidos, contribuem com a menor parcela da receita devido ao baixo ticket médio.





Figura 4: Análise de Receita, Ticket Médio e Desconto por Categoria.

Performance Logística: O serviço **Standard** é o mais utilizado (70% dos pedidos confirmados), com o frete mais baixo, porém o maior prazo de entrega. O serviço **Same-Day**, embora mais caro, cumpre a promessa de entrega rápida. A taxa de atraso, no entanto, é similar entre os três serviços, pairando em torno de 47%.



4. Inferência Estatística

Para validar os achados e fazer generalizações para a população de clientes, foram realizados testes de hipóteses e calculados intervalos de confiança (ICs) com 95% de confiança.

4.1. Verificação de Suposições

Para a realização dos testes paramétricos, como o Intervalo de Confiança (IC) baseado na distribuição t e a Análise de Variância (ANOVA), a suposição de normalidade dos dados é ideal.

Os testes de normalidade (Shapiro-Wilk, D'Agostino-Pearson) rejeitaram a hipótese nula de normalidade para as variáveis financeiras e de tempo ($p < 0.05$). No entanto, devido ao **grande tamanho da amostra** ($n = 4.636$), o **Teorema do Limite Central** garante que a **distribuição amostral das médias** tende à normalidade, permitindo a aplicação robusta dos testes paramétricos.

Além da normalidade, a ANOVA exige a suposição de **homogeneidade das variâncias** (homocedasticidade) entre os grupos. O **Teste de Levene** foi aplicado para verificar se a variância do *Ticket Total* é similar entre as diferentes categorias de produtos.

- **Resultado do Teste de Levene:** [P-valor: $p < 0.001$]
- **Conclusão:** Rejeita H_0 . Variâncias não são homogêneas (Heterocedasticidade).
Interpretação: O p-valor muito baixo ($p < 0.001$) indica que a diferença nas variâncias entre as categorias é estatisticamente significativa. Isso confirma a necessidade de usar testes robustos ou não-paramétricos para comparações de médias.

A documentação completa dos testes de suposição está disponível no notebook `05_statistical_inference.py`.

4.2. Intervalos de Confiança (IC 95%)

Os ICs fornecem uma faixa de valores prováveis para as médias e proporções da população.

- **IC para Ticket Médio Total:** Com 95% de confiança, o ticket médio de todos os clientes do e-commerce está entre **R915,64 e R 990,08**. (Formato simplificado: IC 95% para Ticket Médio = [R915,64; R 990,08]).
- **IC para Taxa de Atraso:** A verdadeira taxa de atraso da operação logística está entre **45.68% e 48.73%**.
- **IC para Taxa de Confirmação:** A proporção de pedidos que são efetivamente pagos e confirmados está entre **88.09% e 89.89%**.




Figura 6: Intervalos de confiança de 95% para as principais métricas de média.

4.3. Testes de Hipóteses

- **Taxa de Confirmação vs. Método de Pagamento:** O teste Qui-Quadrado mostrou uma **associação estatisticamente significativa** ($p < 0.001$) entre o método de pagamento e a confirmação do pedido. Isso confirma que a diferença nas taxas de confirmação entre Boleto/Débito e Crédito/PIX não ocorre ao acaso.

- **Ticket Médio vs. Categoria:** O teste ANOVA revelou **diferenças estatisticamente significativas** ($p < 0.001$) no ticket médio entre as diferentes categorias de produtos, validando que **Eletrônicos** possuem um ticket médio estruturalmente maior que as demais.

5. KPIs e Insights de Negócio

O dashboard abaixo consolida os principais KPIs (Key Performance Indicators) e direciona para os insights mais relevantes.




Figura 7: Dashboard consolidado com os principais KPIs do negócio.

Principais KPIs

Categoria	KPI	Valor
Financeiro	Receita Total (Confirmada)	R\$ 3.915.541,69
	Ticket Médio	R\$ 952,86
	Take-rate de Frete	3.48%
Operacional	Taxa de Confirmação	88.95%
	Taxa de Cancelamento	11.05%
Logístico	Prazo Médio de Entrega	10.1 dias
	Taxa de Atraso	47.20%

Insights Acionáveis

- Ação em Pagamentos:** A diferença de mais de 10 pontos percentuais na taxa de confirmação entre Boleto/Débito e PIX/Crédito é um ponto de atenção. **Recomendação:** Implementar um sistema de recuperação de boletos não pagos (ex: lembretes por e-mail/WhatsApp) e promover o PIX com pequenos incentivos (ex: cashback ou desconto no frete).
- Estratégia de Mix de Produtos:** A alta concentração de receita em Eletrônicos (53%) cria uma dependência. **Recomendação:** Fomentar o crescimento de categorias com boa margem e ticket médio crescente, como **Casa e Decoração** (26% da receita), através de campanhas de marketing direcionadas e kits de produtos (bundles).
- Otimização Logística:** A taxa de atraso de 47% é um ponto crítico que afeta a experiência do cliente. A região Nordeste é a mais impactada. **Recomendação:** Renegociar SLAs (Service Level Agreements) com as transportadoras, diversificar parceiros logísticos na região Nordeste e avaliar a viabilidade de um mini centro de distribuição para reduzir o *lead time*.